

# EEG 데이터를 이용한 알츠하이머병 진단을 위한 딥러닝 기반 분류 모델의 성능 평가

## Performance Evaluation of Deep Learning-Based Classification Models for Alzheimer's Disease Diagnosis Using EEG Data

### 요약

알츠하이머병(Alzheimer's Disease, AD)은 치매의 주된 원인으로 알려진 퇴행성 뇌질환이며, 현재까지 이 병을 근본적으로 치료할 수 있는 방법은 발견되지 않았다. 따라서, 조기 진단과 신속한 대응이 매우 중요하다. 최근 비용 효율적이고 접근성이 뛰어난 뇌파(Electroencephalogram, EEG)를 활용하여 알츠하이머병을 조기에 진단할 수 있는 연구가 활발히 진행되고 있다. 본 연구는 다양한 딥러닝 분류 모델을 활용하여 EEG 데이터로 알츠하이머병을 진단하는 것을 목표로 한다. EEG 데이터를 기반으로 8가지 최적화된 딥러닝 모델들의 성능을 비교 평가하였다. 특히, Leave-One-Subject-Out(LOSO) 검증 방법을 사용하여 각 모델의 분류 성능을 분석하였다. 실험 결과, EEGConformer와 ATCNet이 각각 78.59%와 76.36%의 가장 높은 정확도를 보여주었다. 또한, CNN 기반 모델보다 트랜스포머 네트워크와 Multi-Head Attention 모듈이 통합된 모델이 더 우수한 성능을 보여주었다. 본 연구는 향후 EEG 데이터를 활용한 알츠하이머병 진단을 위한 독자적인 딥러닝 기반 모델 개발의 토대를 마련할 것으로 기대된다.

### 1. 서론

알츠하이머병(Alzheimer's Disease, AD)은 치매의 주된 원인으로 알려진 퇴행성 뇌질환으로[1], 2020년에는 전 세계적으로 5천만 건 이상의 치매가 보고되었으며, 2050년까지 그 수가 1억 3,100만 명에 이를 것으로 추정된다[2]. AD는 주로 기억력 감퇴, 언어 및 인지 기능의 저하, 그리고 행동 변화와 같은 점진적인 증상을 보이며, 현재로서는 질병의 진행을 지연시킬 수 있는 약물 치료만 가능하다.

알츠하이머병의 조기 진단은 이러한 치료 전략의 성공에 중요하며, 진단에는 주로 비용과 시간이 많이 소요되는 MRI나 PET 스캔이 사용된다. 이러한 방법들은 상당한 신경 변성이 진행된 후에야 진단을 받게 되는 경우가 많기 때문에, 비용 효율적이고 접근성이 높은 대안적 방법의 필요성이 대두되고 있다.

뇌파 검사(Electroencephalogram, EEG)는 뇌 내 신경 활동에 의해 발생하는 전기적 활동 변화를 대뇌피질 또는 두피에서 측정하여 기록하는 진단 도구이다[3]. EEG 데이터는 뇌 질환 검출 및 평가를 위한 신뢰할 수 있는 임상 도구로 확립되었으며, 특히 AD의 조기 진단과 진행 모니터링에 유용할 수 있다[4].

최근에는 딥러닝 기술이 EEG 데이터를 활용한 알츠하이머병 진단에 효과적인 접근 방식으로 부상하고 있다. 이 기술은 합성곱 신경망(CNN), 순환 신경망(RNN), 트랜스포머 네트워크 등 다양한 아키텍처를 통해 EEG 신호의 복잡한 패턴을 학습하고, 이를 통해 AD의 잠재적인 생체 지표를 정확하게 식별할 수 있다[5].

본 논문에서는 EEG를 이용하여 알츠하이머병 진단을 위해 최적화된 8가지 딥러닝 기반 분류 모델의 성능을 평가하고 비교한다. 이는 각 모델의 특징과 그 구조가 성능에 미치는 영향을 이해하고, 더 나아가 알츠하이머병의 조기 진단 및 모니터링에 가장 적합한 모델을 선별하는 데 중요한 기여를 할 수 있을 것으로 기대한다.

### 2. 연구 방법

#### 2.1 데이터셋 및 전처리

본 논문은 공개된 뇌파 데이터셋[6]을 사용한다. AD 진단 판정을 받은 36명의 피험자 그룹과, 유사한 조건으로 통제된 29명의 건강한 비교군(Controlled Normal, CN)을 대상으로 측정된 EEG 데이터를 포함한다. EEG 측정은 10-20 국제 전극 시스템을 따르는 19개의 전극에서 이루어졌고(그림 1), 샘플링 비율은 500Hz이다. 눈을 감은 휴식 상태에서 측정이 이루어졌고, AD 그룹에서 치매 관련 동반 질환은 보고되지 않았다. AD 그룹과 CN 그룹의 나이대와 EEG 측정 시간은 유사한 통계치를 보이며, 인지 기능 장애의 정도를 평가하는 표준검사 도구인 MMSE(Mini Mental State Examination) 점수만 극명한 차이를 보였다(표 1).

데이터 전처리를 위해 Butterworth band pass filter를 0.5~45Hz 주파수 대역에서 적용하였고, A1-A2 채널 기준으로 re-referencing 하였다. ASR routine(Artifact Subspace Reconstruction routine)과 독립 성분 분석(Independent Component Analysis, ICA)을 적용하여 잡음을 제거하였다. 각 데이터는 4초 단위로 50%씩 중첩하여 epoching 하여 분류 모델에 적용하였다.




그림 1. 19개의 EEG 채널 몽타주(montage)

표 1. 그룹별 EEG 데이터 주요 통계 지표

그룹(명)	측정 시간 (분)		MMSE (0~30)		나이	
	평균	총계	평균	표준편차	평균	표준편차
AD(36)	13.5	485.5	17.8	4.5	66.4	7.9
CN(29)	13.8	402.0	30.0	0.0	67.9	5.4

## 2.2 딥러닝 기반 분류 모델

### 2.2.1 EEGNet

해당 모델은 block1과 block2로 나누어진다[7]. block1은 Temporal Convolution layer, Depthwise Convolution layer, mean pooling 연산으로 이루어진다. block2는 Separable Convolution layer, mean pooling 연산을 적용한 뒤, Softmax layer로 전달하여 각 클래스의 확률을 예측한다.

### 2.2.2 DeepConvNet

해당 모델은 4개의 Convolution max pooling block으로 구성된다[8]. 첫 번째 block은 Temporal Convolution layer, Spatial filter layer, max pooling 연산을 수행한다. 나머지 3개의 block은 각각 2D Convolution layer, max pooling 연산을 수행한다. 출력값을 Dense Softmax layer로 전달하여 각 클래스의 확률을 예측한다.

### 2.2.3 ShallowConvNet

DeepConvNet을 기반으로 한 얇은 구조의 모델이다. Temporal Convolution layer, Spatial filter layer, mean pooling 연산을 수행한다. DeepConvNet과 달리 추가적인 Convolution pooling layer 없이 출력값을 바로 Dense Softmax layer로 전달하는 것이 특징이다.

### 2.2.4 U-Time

해당 모델은 U-net 구조 기반의 인코딩 단계와 디코딩 단계로 이루어졌다[9]. 인코딩 단계에서는 Convolution과 max pooling 연산을 반복적으로 수행하면서 Down sampling 한다. 디코딩 단계에서는 입력값으로 들어온 이미지에 Nearest Neighbour Up-sampling을 적용한다. 이는 시간 축으로 feature maps의 길이를 2배로 증가시킨다. 1D Convolution layer를 거친 뒤, 대응하는 인코딩 단계의 출력물과 skip connection 한다. 연결된 feature maps에 1D Convolution layer를 적용한다. 마지막 Segment classifier 단계에서 EEG 데이터 채널 별로

mean pooling, Pointwise Convolution을 수행한다.

### 2.2.5 EEGInception

해당 모델은 두 개의 Inception 모듈로 이루어졌다[10]. 첫 번째 Inception 모듈에서는 입력 신호로부터 서로 다른 세 가지 필터 크기를 가진 Temporal Convolution layer, Depthwise Convolution layer 연산을 병렬적으로 수행한다. 연산 결과를 모두 concatenate 한 뒤 mean pooling을 통해 차원을 축소한다. 두 번째 Inception 모듈에서는 첫 번째 Inception 모듈보다 필터 크기를 축소 조정하고, Depthwise Convolution layer만 제외한 연산을 수행한다. 이후 2D Convolution과 mean pooling 연산을 수행하며 차원을 축소하고, Softmax layer로 전달한다.

### 2.2.6 EEGResNET

Deep Residual learning 구조 기반의 모델이다[11]. Temporal Convolution layer, Spatial filter layer를 거친 뒤, ResidualBlock 연산을 수행한다. ResidualBlock은 2번의 2D Convolution layer 연산을 수행한 결과를, 2D Convolution layer 연산 이전의 ResidualBlock 입력값과 더하여(shortcut connection), 다시 ELU 활성화 함수 연산을 수행하는 것을 의미한다. N번의 ResidualBlock 연산을 수행하고, Softmax layer로 전달한다.

### 2.2.7 EEGConformer

해당 모델은 Convolution 모듈, Self-Attention 모듈, Classifier 모듈로 이루어져 있다[12]. Convolution 모듈은 Temporal Convolution layer, Spatial filter layer, mean pooling 연산을 수행한다. Self-Attention 모듈에서는 이전 모듈 결과 feature maps에 Multi Head Attention을 적용한다. Classifier 모듈에선 2개의 fully connected layers를 거쳐 Softmax 함수를 적용한다.

### 2.2.8 ATCNet

해당 모델은 Convolutional block, Attention block, Temporal Convolutional block으로 이루어져 있다[13]. Convolutional block은 Temporal Convolution layer, Spatial filter layer, Temporal Convolution layer, mean pooling 연산을 수행한다. 더불어 Convolutional based sliding window 연산을 수행한다. Attention block에서는 Multi-Head Attention 연산을 수행한다. Temporal Convolutional block은 2번의 Dilated Causal Convolutional layer를 거친 뒤, 입력값을 다시 더해준다.

## 2.3 모델 최적화

Optuna를 활용하여 각 모델마다 최적의 하이퍼파라미터 조합을 탐색하였다. 필터 크기와 개수, pooling, stride, dilation 크기, layer 수, Attention head 수, 학습률, dropout rate를 최적화 대상 하이퍼파라미터로 설정하였다. 각 탐색 시행은 Validation loss 기준으로 5회 이상 개선이 없을 때 과대 적합을 방지하고자 조기 종료하였고, 총 100회의 탐색 결과 가장 우수한 Validation loss를 갖는 하이퍼파라미터 집합으로 각 분류 모델을 설계하였다.

2.4 성능 평가

모델 성능 평가에는 Leave-One-Subject-Out(LOSO) 검증 방법을 사용하였다. 매 Subject Validation마다 AD 그룹, CN 그룹에서 각 3명씩, 총 6명을 랜덤으로 추출하여 검증 데이터셋으로 설정하고, 나머지 48명의 데이터를 훈련 데이터셋으로 설정한다. 학습 시 Validation loss 기준 10회 이상 개선이 없을 때 조기 종료하였다. 모델 간 성능 비교를 위한 기준 분류 평가 지표로 정확도, 재현율, 특이도, F1-Score를 사용한다. 피험자별로 EEG 측정 시간이 상이하기 때문에 데이터 수가 서로 다른 것을 보완하기 위하여, 모든 분류 평가 지표는 각 피험자의 데이터 수에 비례하게 가중 평균 내어 계산하였다.

3. 실험 결과

표 2는 각 모델별 분류 성능 평가 지표를 보여준다. 표 2는 정확도 기준 내림차순으로 정렬되었다. 실험 결과 정확도 기준 EEGConformer가 78.59%로 가장 우수한 성능을 보였고, ATCNet (76.36%), EEGNet (75.11%) 순으로 높은 성능을 보였다. 재현율 기준 DeepConvNet (77.29%), ATCNet (77.14%) 순으로 높은 성능을 보였다. 특이도 기준 EEGConformer (89.74%), EEGInception (78.41%) 순으로 높은 성능을 보였다. F1 Score 기준 DeepConvNet (82.96%), ATCNet (82.19%) 순으로 높은 성능을 보였다.

표 2. 모델 성능 평가 결과

모델	정확도	재현율	특이도	F1-Score
EEGConformer	0.7859	0.6935	0.8974	0.7518
ATCnet	0.7636	0.7714	0.7541	0.8220
EEGNet	0.7511	0.7469	0.7562	0.7979
U-Time	0.7375	0.7322	0.7438	0.8019
DeepConvNet	0.7335	0.7729	0.6860	0.8296
ShallowConvNet	0.7272	0.7214	0.7341	0.7811
EEGResNet	0.6989	0.7291	0.6625	0.7890
EEGInception	0.6889	0.6101	0.7841	0.6813

4. 결론 및 기대 효과

본 연구는 알츠하이머병 진단을 위해 EEG 데이터를 활용한 다양한 딥러닝 기반 분류 모델들의 성능을 정량적으로 비교 및 평가하였다. 8개의 모델을 선정하여 AD 진단에 특화 되게 Fine-Tuning을 실시했으며, LOSO 검증 방법을 통해 각 모델의 일반화 성능을 평가하였다. 실험 결과, EEGConformer와 ATCNet 모델이 각각 78.59%와 76.36%의 정확도를 기록하여 가장 높은 성능을 나타냈으며, 이 두 모델은 트랜스포머 네트워크의 Multi-Head Attention 모듈을 통합하여 구성된 것이 특징이다.

본 연구에서 사용된 데이터셋은 총 65명의 피험자로 구성되어 있다. 이는 상당한 양의 데이터를 포함하고 있지만, 추가 데이터의 수집이나 데이터 증강 기법의 적용을 통해 모델의 표현력과 하이퍼파라미터의 최적화를 더욱 극대화할 수 있을 것으로 기대된다. 또한, 본 연구는 향후 EEG 데이터를 활용하여 알츠하이머병 진단을 위한 독자적인 딥러닝 기반 분류 모델을 개발할 때 중요한 비교 평

가 자료로 활용될 수 있을 것이다. 이는 향후 연구 및 개발 방향을 제시하는 데 큰 도움이 될 것이다. 딥러닝 모델을 이용한 조기 진단 방법은 비용과 시간을 절약하고, 알츠하이머병 환자의 삶의 질을 향상시킬 수 있는 중요한 진전을 제공할 것으로 기대된다.

참 고 문 헌

[1] D. V. Puri, S. L. Nalbalwar, A. B. Nandgaonkar, J. P. Gawande and A. Wagh, "Automatic detection of Alzheimer's disease from EEG signals using low-complexity orthogonal wavelet filter banks", Biomed. Signal Process. Control, vol. 81, 2023.

[2] Y. Ding, Y. Chu, M. Liu, Z. Ling, S. Wang, X. Li, et al., "Fully automated discrimination of Alzheimer's disease using resting-state electroencephalography signals", Quant. Imag. Med. Surgery, vol. 12, no. 2, pp. 1063-1078, 2022.

[3] M. X. Cohen, "Where does EEG come from and what does it mean?", Trends Neurosci., vol. 40, no. 4, pp. 208-218, 2017.

[4] A. Miltiadous, K. D. Tzamourta, N. Giannakeas, M. G. Tsipouras, E. Glavas, "Machine learning algorithms for epilepsy detection based on published EEG databases: A systematic review", IEEE, vol. 11, pp. 564-594, 2023.

[5] J. Xie, J. Zhang, J. Sun, Z. Ma, L. Qin, G. Li, et al., "A transformer based approach combining deep learning network and spatial-temporal information for raw EEG classification", IEEE, vol. 30, pp. 2126-2136, 2022.

[6] Miltiadous, A.; Tzamourta, K.D.; Afrantou, T.; Ioannidis, P.; Grigoriadis, N.; Tsalikakis, D.G.; Angelidis, P.; A Dataset of Scalp EEG Recordings of Alzheimer's Disease, Frontotemporal Dementia and Healthy Subjects from Routine EEG. <https://doi.org/10.3390/data8060095>, 2023.

[7] Lawhern, V. J., Solon, A. J., Waytowich, N. R., Gordon, S. M., Hung, C. P., & Lance, B. J. EEGNet: A Compact Convolutional Network for EEG-based Brain-Computer Interfaces. arXiv preprint arXiv:1611.08024, 2018.

[8] Schirrmester, R. T., Springenberg, J. T., Fiederer, L. D. J., Glasstetter, M., Eggensperger, K., Tangermann, M., Deep learning with convolutional neural networks for EEG decoding and visualization. Human Brain Mapping, 2017.

[9] Perslev M, Darkner S, Kempfner L, Nikolic M, Jennum PJ, Igel C. U-Sleep: resilient high-frequency sleep staging. npj Digit. Med. 4, 72, 2021.

[10] Santamaria-Vazquez, E., Martinez-Cagigal, V., Vaquerizo-Villar, F., & Hornero, R. EEG-inception: A novel deep convolutional neural network for assistive ERP-based brain-computer interfaces. IEEE Transactions on Neural Systems and Rehabilitation Engineering , v. 28, 2020.

[11] He, K.; Zhang, X.; Ren, S.; Sun, J. Deep residual learning for image recognition. In Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770-778, 2016.

[12] Song, Y., Zheng, Q., Liu, B. and Gao, X., EEG conformer: Convolutional transformer for EEG decoding and visualization. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 31, pp.710-719, 2022.

[13] H. Altaheri, G. Muhammad and M. Alsulaiman, "Physics-informed attention temporal convolution network for EEG-based motor imagery classification," in IEEE Transactions on Industrial Informatics, 2022.